

빅데이터 분석을 위한 PYTHON

이 창 훈 과장
디지털혁신실 데이터사이언스팀

2025.7.9-11

Day 1

- 데이터 분석, 빅데이터, Python
- 파이썬 기반 데이터 분석 환경 구축
- 주요 라이브러리 및 한국은행 데이터 분석 라이브러리(bok-da)

Day 2

- 머신러닝 기법
- 빅데이터 분석 실습: 실시간 인플레이션 전망


Day 3

- 빅데이터 분석 실습: 금융·외환 조기경보모형

단계별 데이터 분석

- 분석주제 설정
- 가설 설정(변수 간 관계에 대한 이론·모형)
- **데이터 준비(입수, 전처리, 가공)**
- **분석(경제모형, 머신러닝, 전망, 정책효과)**
- **분석 결과 시각화**
- 보고서 작성 및 코드 공유

BIDAS 기반 데이터 분석 워크플로우



빅데이터

빅데이터의 특성(5 Vs)

- Volume(방대한 규모), Velocity(빠른 생성 및 처리)
- Variety(정형, 비정형), Veracity(신뢰성), Value(유의미한 인사이트)

경제분석에서의 빅데이터

- **대규모 경제·금융 시계열 데이터**(많은 수의 설명변수, feature)
- 텍스트(뉴스 기사) 등의 비정형 데이터(새로운 지수 개발)
- 마트 스캐너 가격 데이터, 전력사용량 등의 대체 데이터

빅데이터 활용 사례

GDP, 인플레이션, 금리, 세계교역량 등의 거시지표 전망

- 이현창 외(2022), 이창훈 외(2024)
- Lenza and Paredes(2023), Chinn et al.(2023)

뉴스심리지수, 인플레이션 어조지수 등 뉴스 기사 기반의 새로운 지표 개발

- 서범석 외(2022), 한승욱 외(2022)

거시 지표 결정요인 분석, 전망에 비전통적 대체 데이터 활용

- BIS-Project Spectrum

다양화된 경제분석 기법(머신러닝)


새로운 데이터 환경(인프라) 및 분석 수요에 효과적으로 대응하기 위해서는

- 탐색적 데이터 분석과 협업이 용이한 환경에서
- 다양한 데이터 처리 도구를 효과적으로 결합하여 활용할 수 있는
- 사용자 인터페이스와 데이터 분석 언어를 선택

⇒ **Python과 Jupyter 생태계**

TIOBE Index for June 2025

TIOBE Index: 전 세계 프로그래밍 언어 인기도 지표



파이썬 특징

오픈소스

다양한 데이터 분석 라이브러리

방대한 사용자 커뮤니티(github, stackoverflow 등)

코드의 간결성(pythonic way of coding: PEP 8, PEP 20)

호환성 문제

실행속도(인터프리터 언어이기 때문에 C/C++에 비해 느림)

파이썬으로 할 수 있는 것

Matlab 대체

Stata 보완

머신러닝

텍스트 분석

데이터 분석 파이프라인 구축

Python 라이브러리

모듈: 코드를 모아 놓은 스크립트 파일(.py 확장자)

```
import inflation
```

패키지: 모듈을 기능별로 구성한 디렉토리

```
import inflation.vintages
```

라이브러리: 모듈과 패키지로 구성

- 통상적으로 패키지과 라이브러리는 같은 의미로 사용

데이터 분석 관련 대표적인 파이썬 라이브러리

- **pandas**: 테이블 행과 열에 이름(label) 부여하여 데이터 처리
- **numpy**: 대규모 다차원 배열(ndarray)과 행렬 연산 처리(matlab)
- **matplotlib/seaborn**: 데이터 시각화 및 커스터마이징
- **statsmodels**: 통계·계량 모형 추정 및 검정
- **sklearn**: 분류·회귀 머신러닝 알고리즘 및 데이터 전처리·검증 기능
- **tensorflow/pytorch**: 심층신경망 모형 설계 및 학습에 특화

파이썬 설치

- 공식 배포판(Python.org), [Anaconda](#)/Miniconda 등

개발환경

- 웹 기반 노트북 인터페이스: Jupyter notebook, JupyterLab
- IDE: vscode with Extensions, PyCharm
- AI 코딩 어시스턴트: vscode with copilot, [Cursor](#)/Windsurf 등
- AI 코딩 에이전트: Claude Code, Google Jules, OpenAI Codex

Anaconda 설치 및 환경 설정

Anaconda 다운로드 및 설치

- [Github](#) Sign up → [링크](#)에서 운영체제별 설치 파일 다운로드
- 설치 마법사 실행 → “Add Anaconda to my PATH environment variable” 체크 해제

가상환경 생성 및 활성화(Anaconda Prompts)

```
# 원하는파이썬버전으로새환경생성
conda create -n myenv python=3.10
# 환경활성화
conda activate myenv
```

Cursor 설치 및 환경 설정

Cursor 다운로드 및 설치

- [링크](#)에서 운영체제별 설치 파일 다운로드
- 설치 마법사 실행

Extensions 설치

- Python, Pylance, Jupyter, Code Runner, GitLens 등 설치

Interpreter 설정

- Cursor: Ctrl+Shift+P → Python: Select Interpreter → myenv

Cursor 설치 및 환경 설정

노트북파일(.ipynb) 만들고 실행 확인

```
import sys
print(sys.executable, sys.version)
```

그래프 테스트

```
import matplotlib.pyplot as plt
plt.plot([1, 2, 3], [4, 5, 6])
plt.title("Matplotlib Test")
plt.show()
```

pandas, numpy, matplotlib

한국은행 데이터 분석 라이브러리(bok-da)

bok-da는 당행 데이터 분석 업무의 **효율성 제고**와 다양한 데이터 분석 코드들을 **지적자산**으로 축적하기 위해 개발

- 데이터 입수 및 시각화, 기본적인 계량경제 분석 도구와 LBVAR, 중립금리 추정모형 등의 고급 거시모형 수록

단계별 데이터 분석 과정을 **단일 인터페이스(BIDAS 고성능 데이터 분석환경)**에서 효율적으로 수행할 수 있도록 지원

- 사용자 매뉴얼 및 예제코드 제공하며, 추후 BIDAS 모델허브에 Reference/Cookbook 수록 예정

bok-da 모듈 구조(디렉토리 구성)

- **data/**: 데이터 입수 및 전처리 관련 코드 디렉토리
- **bayes/**: 베이지안 모형 코드 디렉토리
- **cs/**: 횡단면 데이터 기반 계량모형 디렉토리
- **linear/**: 선형 모형 코드 디렉토리
- **panel/**: 패널 모형 코드 디렉토리
- **patch/**: statsmodels 패키지의 패치를 위한 코드 디렉토리

bok-da 모듈 구조(디렉토리 구성)

- **project/**: 행내 개발 모형 및 분석도구 코드 디렉토리
- **stata/**: 파이썬 환경에서 stata 활용을 위한 코드 디렉토리
- **ts/**: 시계열 모형 코드 디렉토리
- **utils/**: 공용 함수 및 기타 데이터 분석 코드 디렉토리
- **validation/**: 모형 검증 코드 디렉토리
- **viz/**: 시각화 도구 코드 디렉토리

bok-da 설치

bok-da git 리파지토리 복제

```
git clone https://github.com/changhoon0807/bokda.git
```

editable mode로 설치

```
cd folder_name  
pip install -e .
```

실습: Large Bayesian Vector Auto-regression

$$y_t = \sum_{l=1}^p \Phi_l y_{t-l} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \Sigma)$$

$$Y = X\Phi + E, \quad E \sim \mathcal{N}(0, I_T \otimes \Sigma)$$

$$Y = \begin{bmatrix} y'_1 \\ \vdots \\ y'_T \end{bmatrix}, \quad X = \begin{bmatrix} y'_0 & \cdots & y'_{1-p} \\ \vdots & & \\ y'_{T-1} & \cdots & y'_{T-p} \end{bmatrix}, \quad \Phi = \begin{bmatrix} \Phi'_1 \\ \vdots \\ \Phi'_p \end{bmatrix}$$

$$\text{vec}(\Phi) \mid \Sigma \sim \mathcal{N}(\text{vec}(\Phi_0), \Sigma \otimes V_0), \quad \Sigma \sim \mathcal{IW}(\mathbf{S}_0, \nu_0)$$

- 사전평균: Φ_0 (보통 0), 사전분산: V_0
- 역위샷트: $\mathbf{S}_0, \nu_0$
- 사전분산을 어떻게 설정하는지에 따라 Symmetry, Asymmetry, Adaptive, Noninformative로 구분

실습: LBVAR

빅데이터

- 변수 수 K , 시차 p 가 크면 추정 파라미터 K^2p 증가
- 베이지안 수축(Prior Shrinkage)으로 과적합·불안정(차원의 저주) 제어
- 수십 수백 개 거시·금융 지표 동시 모형화

중앙은행 활용 사례

- **거시 전망(Macro Forecasting)**
- **정책 충격 분석:** 통화정책 충격의 파급 효과 구조 분석(Banbura et al.(2008))
- **시나리오분석/조건부예측:** 시나리오로 변수가 주어졌을 때, 조건부 예측(Crump et al.(2021))

실습: Symmetric Prior

$$\text{vec}(\Phi) \mid \Sigma \sim \mathcal{N}(\text{vec}(\Phi_0), \Sigma \otimes (\lambda^{-1} I_{kp})),$$
$$\Sigma \sim \mathcal{IW}(\mathbf{S}_0, \nu_0).$$

- 하이퍼파라미터: $\lambda, \mathbf{S}_0, \nu_0$
- 하나의 λ 로 모든 계수 동일 수축

실습: Asymmetric(Minnesota) Prior

$$\text{Var}(\phi_{ij}(l)) = \begin{cases} \frac{\lambda_1^2}{l^2}, & i = j \\ \frac{\lambda_2^2 \sigma_i^2}{l^2 \sigma_j^2}, & i \neq j \end{cases}$$

$$\text{vec}(\Phi) \mid \Sigma \sim \mathcal{N}(0, \Sigma \otimes V_0), \quad V_0 = \text{diag}\left(\frac{\lambda_1^2}{l^2}, \frac{\lambda_2^2 \sigma_i^2}{l^2 \sigma_j^2}\right),$$

$$\Sigma \sim \mathcal{IW}(\mathbf{S}_0, \nu_0).$$

- 하이퍼파라미터: $\lambda_1, \lambda_2, \mathbf{S}_0, \nu_0$
- own-lag vs cross-lag 구분 수축
- Chan (2022)

실습: Adaptive-Hierarchical Prior

$$\text{vec}(\Phi) \mid \Sigma, \lambda \sim \mathcal{N}(0, \Sigma \otimes (\lambda^{-1}I)),$$

$$\lambda \sim \text{Gamma}(\mathbf{a}, \mathbf{b}),$$

$$\Sigma \sim \mathcal{IW}(\mathbf{S}_0, \nu_0).$$

- 하이퍼파라미터: $\mathbf{a}, \mathbf{b}, \mathbf{S}_0, \nu_0$
- λ 도 데이터 기반 추정
- Chan (2021)

실습: Non-informative(Diffuse) Prior

$$\text{vec}(\Phi) \mid \Sigma \sim \mathcal{N}(0, \Sigma \otimes (\kappa^{-1}I)),$$

$$\Sigma \sim \mathcal{IW}(\Psi_0, \nu_0),$$

$$\kappa \rightarrow 0, \quad \nu_0 \approx K + 1.$$

- 하이퍼파라미터: κ, Ψ_0, ν_0
- 사전분산→무한대로, 평평한 사전

한국은행 스냅샷 스타일 시각화 도구

계량경제모형과 머신러닝

계량경제모형은 변수의 확률분포에 대한 가정하에 변수 간 관계 추정에 초점

- 변수 간 관계는 통상 선형회귀식으로 표현
- 데이터를 모두 사용하여 회귀계수를 추정
- **(모형검증)** 추정결과가 이론에 부합하는지 여부, R^2 , AIC, BIC 등으로 유효성 판단

머신러닝 알고리즘은 확률분포에 대한 가정없이 변수 예측에 초점

- 특정 모형구조(하이퍼 파라미터)하에서 변수 간 관계를 포착하는 패턴(파라미터)을 알고리즘적으로 탐색
- 일부 데이터에 대해 패턴을 학습한 다음 데이터를 이용하여 표본외 예측력(테스트셋) 평가
- **(모형검증)** 표본외 예측력을 기준으로 모형의 유효성을 판단

정규화 회귀(Regularized Regression)

전통적인 **OLS(최소제곱법)**에 penalty항을 더한 형태이면서, 머신러닝 관점에서 **대규모 데이터·고차원(많은 수의 feature)** 상황에서 일반화 성능을 높이기 위한 정규화 기법

OLS의 한계

- 다중공선성: 설명변수가 상관관계가 매우 높으면 $X^T X$ 역행렬이 불안정해 계수 추정치의 분산이 커짐
- 고차원 데이터: 설명변수의 수가 크면 과적합되기 쉬움
- 변수선택: AIC, BIC 기반 변수선택은 계산량이 큼

정규화 회귀

L2 정규화(Ridge regression)

$$\min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \alpha \sum_{j=1}^p \beta_j^2$$

- 계수 제곱합에 따라 모든 β_j 를 0으로 수축
- 중요도가 낮은 계수는 상대적으로 더 크게 수축

L1 정규화(Least Absolute Shrinkage and Selection Operator, Lasso regression))

$$\min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \alpha \sum_{j=1}^p |\beta_j|$$

- 절댓값 합에 따라 일부 β_j 를 정확히 0으로 만들어 변수 선택 효과

Elastic Net(L1 + L2 혼합)

$$\min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \alpha \left(\rho \sum_{j=1}^p |\beta_j| + (1 - \rho) \sum_{j=1}^p \beta_j^2 \right)$$

- L1(sparse) + L2(dense) 페널티를 결합해 상관된 변수도 함께 선택


하이퍼파라미터 튜닝

- α : 정규화 강도 (크면 강한 수축)
- ρ : L1 vs L2 비중 (Elastic Net)
- Grid 서치 또는 랜덤 서치 + 교차검증(CV)

트리(decision tree) 기반 앙상블


의사결정나무(Decision Tree): 데이터를 일련의 '예/아니오' 질문으로 데이터를 분할해 나가며 예측을 수행하는 **비모수(non-parametric) 모형**이며, **분류(Classification)**와 **회귀(Regression)**문제에 모두 사용

Decision Tree for Regression Example



의사결정나무 예시

(예시)단기금리를 feature로 인플레이션을 예측(feature=1, max_depth=2)



- $leaf_1(X \leq 0.3) \rightarrow$ 과거 사례 평균 1.0% $\rightarrow$ predict = 1.0%
- $leaf_2(0.3 < X \leq 0.5) \rightarrow$ 과거 사례 평균 1.5% $\rightarrow$ predict = 1.5%
- $leaf_3(0.5 < X \leq 0.7) \rightarrow$ 과거 사례 평균 2.0% $\rightarrow$ predict = 2.0%
- $leaf_4(X > 0.7) \rightarrow$ 과거 사례 평균 2.5% $\rightarrow$ predict = 2.5%

의사결정나무 분할 기준: RSS 계산 및 분산 감소량

RSS(잔차제곱합) 계산

- 후보 임계값 s 마다 데이터 분할:

$$R_L(s) = \{t : X_t \leq s\}, \quad R_R(s) = \{t : X_t > s\}$$

- 각 그룹의 평균값 계산:

$$\bar{y}_L(s) = \frac{1}{|R_L|} \sum_{t \in R_L(s)} y_t, \quad \bar{y}_R(s) = \frac{1}{|R_R|} \sum_{t \in R_R(s)} y_t$$

- 분할 후 RSS 계산:

$$\text{RSS}(s) = \sum_{t \in R_L(s)} (y_t - \bar{y}_L(s))^2 + \sum_{t \in R_R(s)} (y_t - \bar{y}_R(s))^2$$


분산 감소량(Variance Reduction)

- 분할 전 노드의 RSS: $\text{RSS}_{\text{before}}$
- 분할로 인한 감소량: $\Delta(s) = \text{RSS}_{\text{before}} - \text{RSS}(s)$
- 최적 분할: $s^* = \arg \max_s \Delta(s)$

의사결정나무 주요 하이퍼파라미터

max_depth: 트리의 최대 깊이, 지정하지 않으면 깊이 제한없이 계속분할하여 과적합 위험

max_feature: 분할 후보로 고려할 특성 수



Random Forest(RF)

랜덤 포레스트(Random Forest)는 여러 개의 의사결정나무를 **앙상블(ensemble)**해서 예측 성능을 향상시키는 알고리즘


배깅(Bagging, Bootstrap Aggregating)

- 학습 데이터를 bootstrap(중복 허용) 샘플링하여 B 개의 서브셋을 구성
- 각 서브셋으로 독립적인 의사결정나무 학습
- 예측 시, B 개의 트리 예측을 평균(회귀 문제) 또는 다수결(분류 문제)

특성 랜덤화

- 트리의 노드 분할 단계마다 전체 특성들 중에 `max_features`개만 무작위로 선택
- 이 중에서 최적 분할 조합(feature-threshold)을 찾음으로써 트리들 간의 상관관계(correlation)를 추가로 낮춤
- 앙상블 내 독립적인 트리들이 다양해져 일반화 성능 향상

Random Forest(RF)



Extremely Randomized Tree(EXT)


EXT는 노드 분할시점에 무작위성을 더욱 강화한 앙상블 기반 알고리즘
임계값까지 무작위로 선택

- 랜덤 포레스트가 노드 분할 시점에 선택된 특성의 모든 분할점 (임계치)을 탐색하는 것과 다르게 EXT는 각 특성마다 하나의 임계치를 무작위로 선택
- 단일 트리의 성능은 낮아지지만 더 다양한 분할 방식으로 트리 간 상관관계가 작아져 일반화 성능이 향상되는 효과

Ensemble boosting


모든 트리를 병렬로 독립적으로 동시에 학습하는 **bagging**과 다르게 **boosting**은 **순차적으로** 이전 트리가 틀린 부분을 다음 트리가 **보정**해서 학습하는 방식으로

- Adaboost, Gradient Boost Machine(GBM), LightGBM, XGB




Ensemble boosting

- Gradient Boosting



신경망(Neural Network)

- Perceptron(hidden layer=0), Multi-Layer Perceptron(hidden layer=1), DNN(hidden layer>=2)



Note: This figure exemplifies a deep learning network for image recognition. The network consists of an input layer, three hidden layers, and an output layer. Input layer consists of nodes (the blue circles) storing the RGB values extracted from each pixel of the image file. Each node of the first hidden layer is calculated by an activation function with linear combination of the input layer nodes. The weight used for linear combination (the line connecting each node) and the bias constitute the parameters of the deep learning algorithm. Sigmoid, tanh, ReLU, etc. are used as activation functions.

Source: Waldrop (2019)

머신러닝 코드 실습

빅데이터와 기계학습 알고리즘을 활용한 실시간 인플레이션 전망 BOK 이슈노트 [제2024-5호]

인플레이션 전망 주요 이슈

① 모형

- 모형 식별 오류(Stock and Watson (2010), BOE (2023))
- **비선형성**(Medeiros et al. (2021), Clark et al. (2022))

② 데이터

- **빅데이터**(The illusion of sparsity, Giannone et al. (2021))
- 정책요인(재정정책(재정적 물가이론), 관리물가)
- 해외요인(글로벌 수요·공급 충격에 민감)
- 비정형·대체 데이터(인플레이션 어조지수, web-scraping 데이터)
- 데이터 결측치 문제(ragged-edge 데이터, 공표 시점·시차)

③ 전망 방법

- **실시간 전망**(Faust and Wright (2013))

개발 방향

① 많은 수의 예측변수로 구성된 데이터셋

- 최대 298개 예측변수

② 트리 기반(tree-based) ML 알고리즘

- 랜덤 포레스트(RF, Random Forest), 익스트림 랜덤 트리(EXT, Extremely Randomized Trees)
- 빅데이터, 모형 식별 오류, 비선형성, 변수선택 문제 해결에 적합

③ 실시간 전망 파이프라인 및 시각화

- 데이터 입수·전처리 → 전망 업데이트 → 시각화 → 공유
- 새로 입수된 데이터(realized information)가 전망 업데이트에 미치는 영향을 직관적으로 파악할 수 있도록 시각화(real-time forecasting plot, RTF)

① 목표변수: 전년동월대비 소비자물가지수 상승률

- $\pi_t = (\log P_t - \log P_{t-12}) \times 100$

- 전년동월대비 상승률은 당행 경제전망, 통화정책방향 결정의 기준

② 예측변수: 10개 그룹, 298개 국내외 거시·금융·대체 변수

- 그룹: **가격**, **경기**(생산·경기변동, 소비), **노동시장**, **금융**(통화량·대출, 금리·환율), **수출입**, **자산**(부동산·주식시장), **글로벌**, **에너지**, **재정**, **텍스트**
- 주요변수: 관리물가, 기대인플레이션율, 생산자물가, 수입물가, 콜금리, 유가, 아파트실거래가격지수, 재정수지, 실업률 등

- 예측변수 그룹: 데이터셋을 카테고리 수준과 기존연구에서 활용되는 빈도를 기준으로 **A(298개)**, **B(111개)**, **C(51개)**로 구분
- 대체 데이터 포함·불포함: A, B, C에서 대체 데이터(경제심리지표, 전력사용량 등의 에너지 그룹 변수, 뉴스심리지수 등의 텍스트 데이터)를 제외한 **A'(278개)**, **B'(97개)**, **C'(45개)**도 활용
- 14개 주요변수: 기대인플레이션율, 유가, 수입물가, 관리물가, 재정수지 등

③ 실시간 전망을 위한 **빈티지 데이터셋** 생성

- 매주 금요일 시점의 빈티지 데이터셋(각 시점 이용가능한 정보) 활용
- 빈티지셋을 활용하여, 전망모형의 예측력을 엄밀하게 평가
- 결측치(ragged-edge)는 전기값, AR 등 단변량 예측으로 보간

① 트리 기반 머신러닝

- 장점: 정형 데이터 대상 강건하고(robust), 높은 예측력 보임
- 대표모형: Random Forest(RF), Extremely Randomized Trees(EXT)
- 예측변수: A, B, C 데이터셋(대체 데이터 제외한 A', B', C')

② 선형회귀


- 장점: 해석이 용이하고, 변수간 관계에 대한 특별한 가정을 하지 않음
데이터 개수가 충분하지 않은 경우, 다른 전망모형에 비해 뛰어난 예측성능
- 예측변수: 14개 주요 예측변수 조합

→ **앙상블**(Ensemble, ENS): 머신러닝(C') + 선형회귀

③ 벤치마크 모형: $RW, ARIMA$

실시간 전망 프로세스


- 매주 금요일 당월($h = 0$), 3개월($h = 3$), 12개월($h = 12$) 인플레이션을 전망하고, 직전 전망치 대비 변동을 변수별로 분해



* $t = 2023$ 년 10월, $t(-1)$ 은 t 월 마지막주 금요일, $t(-2)$ 는 t 월 마지막 두번째주 금요일,...

실시간 전망 데이터 파이프라인

- 데이터 파이프라인을 통한 실시간 인플레이션 전망 프로세스 자동화



Walk-forward validation

① RMSE, MAE

- 전망시점별(w) RMSE, MAE 그래프가 우하향 할 경우 신규 정보가 예측력 개선에 도움이된다고 볼 수 있음

$$\blacksquare RMSE = \sqrt{\frac{\sum_{t=T_0+1}^T (\pi_{t+h} - \hat{\pi}_{t+h|t(-w)})^2}{T - T_0}}, MAE = \frac{\sum_{t=T_0+1}^T \text{abs}(\pi_{t+h} - \hat{\pi}_{t+h|t(-w)})}{T - T_0}$$

여기서, $\pi_{t+h} = t + h$ 월 실제치, $\hat{\pi}_{t+h|t(-w)} = t$ 월 $-w$ 주 기준 $t + h$ 월 전망치

$t = T_0 + 1, T_0 + 2, \dots, T, \quad h = 0, 3, 12, \quad w = 1, 2, 3, 4$

② MDA(Mean Directional Accuracy)

- 실제 인플레이션 변동 방향에 대한 예측력 평가 기준(매월 마지막 전망기준)

$$\blacksquare MDA = \frac{1}{(T - T_0)} \sum 1[\text{sgn}(\pi_{t+h} - \pi_{t+h-1}) = \text{sgn}(\hat{\pi}_{t+h|t(-w)} - \pi_{t+h-1})], 0 \leq MDA \leq 1$$

③ 평가 기간: [2016.1 - 2023.9], [2016.1 - 2020.12], [2021.1 - 2023.9]

MDA 결과

- 변동폭이 큰 기간에 인플레이션 방향 예측력 높음


- 전체기간중 모든 전망시계에서 MDA 는 0.6 이상
(큰 변동이 발생한 시점에 대해서만 계산할 경우 0.8 이상)
- 2021년 이후 기간중 MDA 는 0.7(0.9) 이상

전망구간	$h = 0$	$h = 3$	$h = 12$
2016년 이후	0.68 (0.85)	0.65 (0.85)	0.72 (0.85)
2016년 ~ 2020년	0.65 (0.78)	0.58 (0.67)	0.73 (0.87)
2021년 이후	0.75 (0.93)	0.76 (1.00)	0.75 (1.00)

* ()안의 숫자는 변동성이 큰 시기(표준편차1 이상인 기간)에 대한 MDA

우리나라 인플레이션 추이


- 전년동월대비 소비자물가지수 상승률



*수직선은 시간 순서대로 2020년 10월, 2022년 7월을 나타냄







What if ... 2020. 10.

2020.10월 인플레이션 전망



What if ... 2022. 7.

2022.07월 인플레이션 전망



인플레이션 가상환경 생성

```
conda create -n inflation python=3.9.16
```

pandas, numpy 설치

```
pip install pandas==1.5.3  
pip install numpy==1.22.4
```

데이터 기반 금융·외환 조기경보모형 BOK 이슈노트 [제2024-11호]

금융위기 발생 메커니즘

금융시스템 **취약성**이 높은 상황에서 실물/금융부문의 **충격(트리거)** 발생 시 디레버리징과 자산가격 급락 악순환 등으로 촉발(IMF 2010, 금안보고서 2021)

- 금융취약성은 가계/기업의 부채비율 및 자산가격 상승, 금융기관의 취약한 자금조달구조 등을 의미하며 장기시계에서 순환
- 트리거는 긴축적 통화정책, 지정학적 리스크 등 이벤트에 의한 불확실성 확대와 이로 인한 위험회피 행태를 포괄

시기별로 취약부문 및 트리거 이벤트가 상이

- '90년대 외환위기, '08년 글로벌 금융위기 등

주요 조기경보모형

신호추출법(signal extraction extraction)

- Kaminsky and Reinhart(1999), Kaminsky(1999)
- 대표적 비모수 모형으로 표본외 예측력이 높음(국제금융센터, IMF)

Logit/Probit 모형

- Frankel and Rose (1996), Demirguc Kunt and Detragiache(1998)

머신러닝(machine learning) 알고리즘

- BoE(2020), IMF(2021)

IMF EWE(Early Warning Exercise, 2010)

- 분야별 전문가의 정성적 리스크 요인 식별 , 서베이 등으로 구성
- 신호추출 , 기계학습 기반 VE(Vulnerability Exercise) 포함

(참고) 신호추출법(Signal Extraction Approach)

1. 후보 지표 선정

- 신용스프레드, 주가수익비율(P/E), 외환보유액 비율, 주택가격 갭 등

2. 임계값(threshold) 결정

$$S_t = \begin{cases} 1 & X_t > k \\ 0 & X_t \leq k \end{cases}, \quad k^* = \arg \min_k \frac{\text{FAR}(k)}{\text{CSR}(k)}$$

3. 개별 신호 생성 $S_{i,t} = 1$ if $X_{i,t} > k_i^*$, else 0

4. 신호 종합 및 경보 발령

- 단순 합산: $S_t^{\text{total}} = \sum_{i=1}^m S_{i,t}$
- 가중 합산: $W_t = \sum_i w_i S_{i,t}$
- 임계치 초과 시 위기 경보

5. 성과 평가 및 최적화

- 재현율(CSR), 오경보율(FAR), Noise-to-Signal 비율 등
- 임계값 · 가중치 · 경보 기준 조정

조기경보모형 개발의 제약 요인

상호의존성 금융위기는 취약성, 트리거 변수 간 상호작용에 의해 발생

- 신호추출모형, 로짓/프로빗은 여러 변수 간 상호 의존성을 포착하지 못함

데이터 부족 국가별 금융위기 발생 사례가 적음

- 과거 위기 발생 사례에 과적합(over-fitting)될 가능성이 높음
- 국가 패널 데이터를 구성할 경우 사용할 수 있는 변수가 제한적

복합금융압력지수(CFPI)를 정의하여 시장불안·위기 기간 식별

- 금융위기와 시장불안 시기를 함께 활용함으로써 데이터 부족 문제를 완화

머신러닝 알고리즘을 이용하여 데이터에 내재한 정보를 효율적으로 활용

- 변수 간 비선형, 상호의존적 관계 포착
- 시기별 취약성(신용, 자산가격, 외채 등) 및 트리거(VIX, 환율, 금리 등) 식별


표본외 예측력을 기준으로 조기경보모형의 실효성을 평가

- 동일한 방식으로 기존 조기경보모형(신호추출, 로짓/프로빗)과 머신러닝 알고리즘을 학습하여 모형별 표본외 예측력(**ROC-AUC**)을 평가

복합금융압력지수(Composite Financial Pressure Index)

- **복합금융압력지수 (CFPI) = 은행부문압력지수 + 채권·증권부문압력지수 + 외환부문압력지수**
- **은행부문압력지수 = KRX 은행 지수 변동성(GARCH)**
+ CD스프레드(CD수익률-통안증권 수익률)
- **채권·증권부문압력지수 = KRX 지수 변동성(GARCH)**
 - KOSPI 지수 수익률
 - 기간프리미엄(국채3년물-통안증권1년물)
 - + 신용스프레드(회사채AA3년물-국채3년물)
- **외환부문압력지수 = USD/KRW 환율 변동성(GARCH)**

〈그림 1〉 복합금융압력지수(CFPI) 추이




주: 가로 점선은 CFPI의 1표준편차, 음영은 CFPI가 1표준편차를 상회한 시장불안(market stress) 기간을 표시한다, 세로 점선은 GDP 성장률(전기 대비)이 지난 4분기 평균보다 1표준편차 이상 하락한 시점을 나타낸다.

데이터

- 전체기간을 정상, 경보, 불안, 경보전 6개월 기간으로 구분하고, 0, 1로 라벨링

period	variables					group	label
	er_std	vix	cp_sp	bank_lev	...		
2007-09	2.04	22.21	0.33	14.95	...	166	0
2007-10	1.99	19.12	0.39	14.84	...	167	0
2007-11	1.96	25.59	0.48	14.84	...	171	0
2007-12	1.90	21.66	0.84	14.84	...	171	0
2008-01	1.90	25.82	1.07	14.73	...	171	0
2008-02	1.84	25.45	0.27	14.73	...	171	1
2008-03	1.78	27.11	0.06	14.73	...	171	1
2008-04	2.57	21.57	0.34	16.03	...	171	1
2008-05	2.40	18.31	0.29	16.03	...	171	1
2008-06	3.21	22.10	0.24	16.03	...	171	1
2008-07	3.21	24.32	0.40	16.04	...	171	1
2008-08	2.90	20.70	0.44	16.04	...	171	1
2008-09	2.71	30.24	0.53	16.04	...	171	1
2008-10	4.12	61.19	1.51	17.33	...	171	1
2008-11	6.85	62.65	2.52	17.33	...	171	1
2008-12	5.93	52.40	2.42	17.33	...	171	1
2009-01	5.05	44.69	1.25	16.56	...	171	1
2009-02	4.33	45.58	0.75	16.56	...	171	1
2009-03	4.87	44.80	0.77	16.56	...	171	1
2009-04	4.26	38.07	0.49	16.75	...	171	1
2009-05	4.76	31.99	0.26	16.75	...	171	1
2009-06	4.08	29.15	0.03	16.75	...	171	0
2009-07	3.55	26.16	-0.08	15.87	...	171	0
2009-08	3.35	25.35	-0.12	15.87	...	171	0
2009-09	3.12	24.94	-0.25	15.87	...	175	0
2009-10	2.78	24.25	-1.13	15.09	...	176	0



데이터

CFSI (외환·은행·채권압력지수) 트리거 (VIX, 환율, 금리) 취약성 (신용, 자산가격, 외채)

Label(y)	예측변수(X)					
0 (안정)	0.62	0.09	0.94	0.94	0.68	0.19
0 (안정)	0.54	0.86	0.41	0.17	0.54	0.20
1 (경보)	0.50	0.54	0.40	0.64	0.84	0.23
1 (경보)	0.16	0.97	0.55	0.66	0.35	0.09

예측력($y, \hat{y}$) $\hat{y} = f(X; \theta)$

예측변수			주기
취약성	레버리지	가계신용/GDP	Q
		기업신용/GDP	Q
	자금조달	단기외채 비율	Q
		은행 레버리지	M
		은행 예대율	M
	자산가격	주택가격	M
트리거	금리	CD 스프레드	D
		CP 스프레드	D
		국가 신용 스프레드	D
		기간 프리미엄 스프레드	D
	변동성	KOSPI 변동성	D
		은행지수 변동성	D
		VIX	D
		환율 변동성	D
	경기	GDP 성장률	Q

- 트리(decision tree) 기반 앙상블: RF, ET, XGB
- 정규화(reguralization) 회귀: Ridge, Lasso, ElasticNet
- 심층신경망(Neural Network)
- Support Vector Machine
- Signal extraction(벤치마크)

검증: Stratified Group K-Fold 교차검증

K-fold 교차검증

- 전체 데이터를 K개의 같은 크기의 데이터셋(fold)으로 나눔
- 1개의 fold를 테스트셋으로 K-1개의 fold를 학습셋으로 사용하여 학습과 평가를 반복
- AUC 등의 기준으로 보지 않은 데이터에 대한 모형의 일반화 성능을 검증



Stratified

- 조기경보모형은 위기, 정상의 클래스 분포가 불균형하기 때문에 Fold에 위기 샘플이 없을 수 있음
- stratified K-fold: 각 fold의 위기, 정상 비율이 전체 데이터의 비율과 유사하도록 분할

Group

- 조기경보모형은 같은 위기국면(그룹)의 데이터가 강하게 상호 연관되어 있음
- 단순 K-fold는 위기 국면의 일부가 학습셋에 나머지가 테스트에 들어가 정보 누수(leakage)가 발생할 수 있음
- group K-fold: 같은 그룹은 학습셋과 테스트셋에 절대 섞이지 않도록 분할

- stratified group K-fold 예시




ROC-AUC

- 라벨이 **Negative**, **Positive**로 주어지고 예측모형은 0과 1 사이의 값을 가질 때 모형 예측력은 두가지 방식으로 평가
- [1]** 임계값(t)을 설정하여 예측값이 t보다 크면 **P**, 작으면 **N**을 예측한 것으로 하여 Precision, Recall, F1 등 계산
 - $\text{Precision} = \#TP / (\#TP + \#FP)$, $\text{Recall} = \#TP / (\#TP + \#FN)$,
 $\text{F1} = 2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})$
 - 임계값 수준에 따라 모형 예측력에 대한 평가가 달라짐
- [2]** 모형의 TPR-FPR 곡선(ROC) 아래 면적(AUC)을 계산하는 것으로 1에 가까울수록 예측력이 우수
 - $\text{TPR} (= \#TP / (\#TP + \#FN))$, $\text{FPR} (= \#FP / (\#FP + \#TN))$
 - $\text{AUC}=1$ 이면 임계값에 관계없이 $\text{TPR}=1$, $\text{FPR}=0$

	Actual Positive	Actual Negative
Predicted Positive	True Positive(TP)	False Positive(FP) (Type I Error)
Predicted Negative	False Negative(FN) (Type II Error)	True Negative(TN)

#TP는 True Positive에 속하는 관측치 수



검증 결과


- 트리 기반 앙상블 머신러닝(ET, RF)의 예측력이 가장 우월
- 신호추출법(SE) 대비 높은 예측력

〈표 1〉 모델별 ROC-AUC

	신호 추출법 (BM)	트리 앙상블			SVM	로지 스틱
		ET	RF	XGB		LR
평균	0.84	0.95	0.93	0.91	0.92	0.76

주: stratified group K-fold 교차검증을 5회 반복하여 계산된 AUC의 평균값

〈그림 7〉 모델별 ROC



조기경보모형 코드 실습

감사합니다.